Manual de Usuario

Pipeline de Predicción de Actividad de Péptidos

Script:
`peptide_activity_prediction_v7.R`

Modelos: Random Forest + Red Neuronal (PCA) + Red Neuronal (ANOVA)

Versión 7 — 2025–2026 — Javier Badilla

1. Introducción

Este script de R implementa un pipeline de aprendizaje automático para predecir si un péptido pertenece a una clase de actividad biológica determinada (en este manual, usaremos de ejemplo: anticongelante {AFP}, antifúngíco {FUNG}, anticanceroso {CANCER}, inhibidor de AChE {AChE}). A partir de descriptores moleculares numéricos calculados previamente, el pipeline entrena tres modelos independientes, los combina en un ensamble y genera predicciones calibradas con un nivel de confianza regulable.

El resultado final es un archivo Excel con 10 hojas que detallan las predicciones, el rendimiento de cada modelo, la importancia de los descriptores y la distribución espacial de los péptidos en el espacio de descriptores.

1.1 ¿Qué hace el script, en resumen?

Etapa	Descripción
1. Limpieza	Elimina duplicados, convierte etiquetas a binario (clase objetivo vs. todo lo demás), verifica desbalance de clases
2. Selección de descriptores	Filtra descriptores por AUC individual ≥ 0.60, luego aplica filtro de correlación ≤ 0.90 para eliminar redundancias
3. División train/test	Separa 80% para entrenamiento y 20% para evaluación. Esta división ocurre ANTES de la selección de descriptores para evitar fuga de datos
4. Entrenamiento (20 corridas)	Entrena tres modelos independientes en cada corrida: Random Forest, Red Neuronal + PCA, Red Neuronal + ANOVA. Cada corrida usa una semilla diferente para medir estabilidad
5. Calibración	Aplica escalado de Platt para corregir las probabilidades brutas de cada modelo
6. Ensemble	Combina los tres modelos con pesos proporcionales al AUC promedio de cada uno
7. Predicciones	Genera probabilidades y clasificaciones a tres umbrales (50%, 70%, 90%) con nivel de confianza
8. Salida	Escribe un Excel con 10 hojas y dos gráficas PCA 3D interactivas en HTML

1.2 Conceptos clave

Descriptores moleculares: Valores numéricos que describen propiedades físicoquímicas de un péptido (carga, hidrofobicidad, peso molecular, etc.). Son la entrada del modelo.

AUC (Area Under the Curve): Métrica de rendimiento de un clasificador. Va de 0.5 (aleatorio) a 1.0 (perfecto). Un descriptor con AUC alto puede por sí solo discriminar entre clases.

Random Forest (RF): Método de ensamble de árboles de decisión. Robusto ante descriptores irrelevantes y distribución no normal. Proporciona importancia de descriptores.

Red Neuronal (NN): Modelo de aprendizaje profundo simplificado (una capa oculta). Más flexible que RF pero requiere normalización de datos.

PCA (Análisis de Componentes Principales): Reduce dimensionalidad combinando descriptores correlacionados en componentes ortogonales. Se usa como preprocesado para una de las redes neuronales.

Ensemble ponderado: Combinación de los tres modelos donde cada uno contribuye en proporción a su AUC promedio. Reduce la varianza de predicción y mejora la robustez.

Escalado de Platt: Ajuste de las probabilidades brutas del modelo usando una regresión logística sobre un subconjunto de calibración. Corrige el sesgo sistemático de probabilidades en RF y NN.

SMOTE: Técnica de sobre-muestreo sintético. Se aplica automáticamente cuando la clase mayoritaria supera en más de 3x a la minoritaria, para evitar que el modelo ignore la clase rara.

1.3 Requisitos del sistema

Elemento	Notas
R	Requerido como base
readxl	Lectura de archivos Excel de entrada
openxlsx	Escritura del Excel de salida
caret	Marco de entrenamiento y validación cruzada
ranger	Implementación eficiente de Random Forest
nnet	Red neuronal de una capa oculta
pROC	Cálculo de AUC y curvas ROC
recipes	Preprocesado declarativo de datos
themis	Implementación de SMOTE para desbalance
dplyr	Manipulación de dataframes
plotly	Gráficas PCA 3D interactivas
htmlwidgets	Guardado de gráficas como HTML

2. Preparación de datos

2.1 Formato de los archivos de entrada

El script requiere dos objetos de datos ya cargados en el entorno de R antes de ejecutarse. Ambos deben estar en formato de dataframe (tabla).

train_data — datos de entrenamiento

Tabla con péptidos de actividad conocida. Columnas obligatorias:

- **ID:** Identificador único de cada péptido (texto).
- **Type:** Clase de actividad (ej: AFP, FUNG, CANCER, AChE). Esta es la variable a predecir.
- **descriptor1, descriptor2, ...:** Valores numéricos de los descriptores moleculares.

```
# Ejemplo de estructura ID       | Type  | MW     | Charge | Hydrophobicity
| ... PEP_001  | AFP   | 1243.5 | +2     | 0.43           | ... PEP_002  |
FUNG  | 987.2  | -1     | 0.61           | ...
```

new_data — péptidos con actividad desconocida

Tabla con los péptidos candidatos cuya actividad se desea predecir. Columnas obligatorias:

- **ID:** Identificador único.
- **descriptor1, descriptor2, ...:** Exactamente los mismos descriptores que en train_data, en el mismo orden. No lleva columna Type.

2.3 Preparación del conjunto de entrenamiento (cap a 300)

Si alguna clase tiene más de 300 muestras, se recomienda limitar a 300 antes de ejecutar el script. Esto evita que clases muy grandes dominen el entrenamiento y reduce el tiempo de cómputo.

3. Configuración del script

Antes de ejecutar el script, edite los parámetros en la sección USER INPUTS al inicio del archivo:

```
target_class     <- "AFP"    # clase que quiere predecir comparison_class <-
"FUNG"  # NULL = uno contra todos  n_runs           <- 20      # número de
corridas de entrenamiento prob_threshold   <- 0.90    # umbral para columnas
de frecuencia  auc_lower        <- 0.60    # AUC mínimo para conservar un
descriptor corr_threshold   <- 0.90    # umbral para filtro de correlación
```

Parámetro	Tipo	Descripción	Valor recomendado
target_class	texto	La clase que el modelo aprenderá a identificar. Debe existir en la columna Type del train_data.	Ej: "AFP", "FUNG"
comparison_class	texto o NULL	Si se especifica, el modelo solo entrena con target_class vs. esta clase. Si es NULL, entrena target_class contra todas las demás clases combinadas.	NULL para análisis general; especificar cuando las clases son muy distintas entre sí
n_runs	entero	Cuántas veces se repite el ciclo completo de entrenamiento con semillas diferentes. Más corridas = predicciones más estables pero mayor tiempo.	20
prob_threshold	decimal 0-1	Umbral para calcular con qué frecuencia cada modelo supera ese nivel de probabilidad en las corridas. Se usa en las columnas RF_Freq, NN_PCA_Freq, NN_Desc_Freq.	0.90
auc_lower	decimal 0-1	AUC mínimo que debe tener un descriptor individualmente para ser conservado. Descriptores por debajo se eliminan.	0.60 (se relaja a 0.55 automáticamente si quedan menos de 10 descriptores)
corr_threshold	decimal 0-1	Si dos descriptores tienen una correlación mayor a este valor, uno se elimina. Reduce redundancia.	0.90

3.1 Modos de clasificación

Modo uno contra todos (comparison_class = NULL)

El modelo aprende a distinguir la clase objetivo de TODAS las demás clases combinadas. Único cuando se tiene un conjunto diverso de péptidos no relacionados como clase negativa. Es el modo más general.

Modo binario estricto (comparison_class = "FUNG")

El modelo solo entrena con los péptidos de las dos clases especificadas. El conjunto de entrenamiento se filtra previamente. Este modo es más preciso cuando las dos clases son las de mayor interés comparativo, pero puede sobreajustarse si las clases son muy similares.

4. Ejecución del script

4.1 Pasos para correr el script

1. Abrir RStudio.
2. Cargue los datos de entrenamiento y los nuevos péptidos (a través de la interfaz de Rstudio para facilitar la operación).
3. Abra el archivo peptide_activity_prediction_v7.R.
4. Edite la sección USER INPUTS con su clase objetivo y parámetros (ver sección 3).
5. Ejecute el script completo (Ctrl+Shift+Enter en RStudio).
6. El script imprime en consola el progreso de cada corrida. El tiempo típico depende del tamaño del dataset.

4.2 Qué aparece en consola durante la ejecución

El script imprime información de progreso en cada etapa. A continuación se describe lo que verá:

Mensaje en consola	Qué significa
Class distribution:	Conteo de muestras por clase en el conjunto de entrenamiento
Imbalance ratio: X.XX	Razón entre la clase más frecuente y la menos frecuente. Si supera 3, se activará SMOTE
*** Imbalance > 3 detected - SMOTE will be applied ***	Aviso: el dataset está desbalanceado y se aplicará sobremuestreo sintético automáticamente
Features with AUC >= 0.60: XX	Número de descriptores que pasaron el primer filtro
Duplicate samples between train/test: 0	Confirmación de que no hay fuga de datos entre entrenamiento y prueba
===== RUN X of 20 =====	Inicio de cada corrida del bucle de entrenamiento
[RF] Post-corr columns: XX | Grid: YY combos	Número de descriptores después del filtro de correlación y tamaño de la grilla de búsqueda para RF
[RF] Test AUC: 0.XXXX	AUC del Random Forest en esa corrida sobre el conjunto de prueba externo
[NN-PCA] Test AUC: 0.XXXX	AUC de la Red Neuronal + PCA en esa corrida
[NN-ANOVA] Test AUC: 0.XXXX	AUC de la Red Neuronal + ANOVA en esa corrida
Model weights: RF: 0.XX NN_PCA: 0.XX NN_ANOVA: 0.XX	Pesos asignados a cada modelo en el ensemble, proporcionales a su AUC promedio
HIGH-CONFIDENCE AFP CANDIDATES: X	Número de péptidos nuevos con predicción positiva a umbral 70% y confianza Alta o Muy Alta

4.3 Archivos generados

Archivo	Descripción
AFP_Complete_Analysis_v2_clean.xlsx	Excel principal con 10 hojas de resultados (el prefijo cambia según target_class)
AFP_PCA_3D_Training.html	Gráfica 3D interactiva del espacio PCA solo con datos de entrenamiento
AFP_PCA_3D_Combined.html	Gráfica 3D interactiva con datos de entrenamiento Y péptidos nuevos superpuestos

5. Interpretación del archivo Excel de salida

El Excel contiene 10 hojas. A continuación se describe el contenido y la interpretación de cada una, en orden de prioridad práctica.

5.1 Hoja 2_Simple_Predictions — Predicciones simplificadas

Es la hoja más directa y la primera que debe revisar. Tiene una fila por cada péptido nuevo.

Columna	Qué significa
ID	Identificador del péptido, tomado de new_data
Is_AFP (o Is_[clase])	YES si la probabilidad ensemble supera el 50%, NO en caso contrario
AFP_Probability_%	Probabilidad ensemble expresada en porcentaje (0–100). Representa la confianza combinada de los tres modelos de que el péptido pertenece a la clase objetivo
Confidence	Nivel de confianza cualitativo (Very High / High / Medium / Low). Ver tabla de rangos abajo

Confidence	Rango de probabilidad	Interpretación
Very High	> 90% o < 10%	Los tres modelos coinciden ampliamente. Predicción muy robusta.
High	> 70% o < 30%	Clara mayoría de los modelos coincide. Predicción confiable.
Medium	> 60% o < 40%	Tendencia clara pero no contundente. Considerar contexto.
Low	40% – 60%	Zona de incertidumbre. Los modelos no tienen consenso. Interpretar con cautela.

5.2 Hoja 4_High_Confidence — Candidatos de alta confianza

Lista filtrada con solo los péptidos que cumplen ambas condiciones simultáneamente: predicción positiva al umbral del 70% Y nivel de confianza High o Very High. Esta es la lista de candidatos prioritarios para validación experimental.

Están ordenados de mayor a menor probabilidad ensemble. Si un péptido aparece aquí con Confidence Very High y los tres modelos de acuerdo (Models_Agree_90 = 3), es el candidato más sólido del análisis.

5.3 Hoja 3_Detailed_Predictions — Predicciones detalladas

Contiene toda la información de predicción para cada péptido. Úl para análisis más granular.

Columna	Qué significa
Ensemble_Probability	Probabilidad final ponderada por AUC de los tres modelos (valor entre 0 y 1)
Prediction_50	Predicción usando umbral del 50%: clásico, maximiza el número de positivos detectados pero puede incluir falsos positivos
Prediction_70	Umbral del 70%: balance entre precisión y recall. Recomendado para selección de candidatos
Prediction_90	Umbral del 90%: solo los más seguros. Muy conservador, puede perder positivos reales
Confidence	Nivel de confianza cualitativo (igual que en hoja 2)
Models_Agree_90	Cuántos de los 3 modelos superaron el umbral de 90% en el promedio de corridas. Valor de 0 a 3. 3 = consenso total
RF_Prob	Probabilidad promedio del Random Forest en las 20 corridas
NN_PCA_Prob	Probabilidad promedio de la Red Neuronal + PCA en las 20 corridas
NN_DESC_Prob	Probabilidad promedio de la Red Neuronal + ANOVA en las 20 corridas
RF_Pred / NN_PCA_Pred / NN_DESC_Pred	Predicción individual de cada modelo al umbral del 50%
Interpretation	Resumen en texto: 'POSITIVE for AFP (High confidence)'

5.4 Hoja 5_Consensus — Análisis de consenso

Muestra con qué frecuencia, a lo largo de las 20 corridas, cada modelo clasificó al péptido como positivo al umbral configurado (prob_threshold = 0.90 por defecto).

Columna	Qué significa
RF_Mean / NN_PCA_Mean / NN_Desc_Mean	Probabilidad promedio de cada modelo a lo largo de las 20 corridas
RF_SD / NN_PCA_SD / NN_Desc_SD	Desviación estándar entre corridas. Un SD alto indica que el modelo es inestable para ese péptido
RF_Freq / NN_PCA_Freq / NN_Desc_Freq	Fracción de las 20 corridas en que el modelo superó el umbral (0.90). Ej: 0.85 = superó el umbral en 17 de 20 corridas
Consensus_Mean	Promedio de las tres frecuencias. Mide qué tan consistentemente todos los modelos clasifican el péptido como positivo
Models_80	Número de modelos que superaron frecuencia ≥ 0.80
Confidence_Tier	Very High: Consensus_Mean ≥ 0.9 y los 3 modelos con frecuencia ≥ 0.8. High: Consensus_Mean ≥ 0.8 y al menos 2 modelos. Low: resto

Cómo interpretar el SD: Un péptido con probabilidad promedio 0.85 pero SD = 0.20 indica que en algunas corridas el modelo lo clasificó como positivo fuerte y en otras como negativo. Esto señala que la predicción es sensible a la muestra de entrenamiento y debe tomarse con cautela. Un SD ≤ 0.10 indica robustez.

5.5 Hoja 6_Model_Evaluation — Rendimiento de los modelos

Resumen del rendimiento de cada modelo medido en el conjunto de prueba externo (el 20% reservado antes del entrenamiento).

Columna	Qué significa
Model	Nombre del modelo: RF, NN_PCA, NN_DESC_ANOVA, Ensemble_Weight
Mean_AUC	AUC promedio en las 20 corridas. Es la métrica principal de calidad del modelo
SD_AUC	Variabilidad del AUC entre corridas. Un SD alto (≥ 0.05) indica inestabilidad
Min_AUC / Max_AUC	Valores extremos del AUC en las 20 corridas. Permiten ver el rango de rendimiento
Ensemble_Weight	Peso asignado al modelo en el ensemble. Proporcional a su Mean_AUC. Solo para los tres modelos base (no para Ensemble_Weight)

AUC promedio	Calidad del modelo
≥ 0.90	Excelente. El modelo discrimina muy bien entre clases.
0.80 – 0.89	Bueno. Predicciones confiables.
0.70 – 0.79	Aceptable. Útil pero con limitaciones.
0.60 – 0.69	Débil. Las predicciones deben tomarse como indicativas.
< 0.60	Poco mejor que azar. Revisar calidad de los datos de entrenamiento.

5.6 Hoja 7_Feature_Importance — Importancia de descriptores

Lista todos los descriptores usados por el Random Forest ordenados de mayor a menor importancia. La importancia se calcula por cuánto empeora el modelo al variar ese descriptor.

Los descriptores con mayor importancia son los más informativos para distinguir la clase objetivo. Esta información puede guiar el diseño de nuevos péptidos: un péptido nuevo con valores favorables en los descriptores de alta importancia tiene mayor probabilidad de ser clasificado como positivo.

El script también imprime en consola si la clasificación se basa en pocos descriptores (top 5 > 70% de la importancia total) o si está distribuida entre muchos.

5.7 Hoja 8_Top_Features_Stats — Estadísticas de los 5 mejores descriptores

Para los 5 descriptores más importantes, muestra el valor promedio en la clase objetivo (Target_Mean) y en la clase de comparación (Other_Mean), así como la diferencia entre ambos. Permite entender en qué dirección debe estar el descriptor para que un péptido sea clasificado como positivo.

Ejemplo de interpretación: Si Hydrophobicity tiene Target_Mean = 0.65 y Other_Mean = 0.32, significa que los péptidos AFP típicamente tienen mayor hidrofobicidad que los demás. Un nuevo péptido con hidrofobicidad alta tendrá más probabilidad de ser clasificado como AFP.

5.8 Hoja 9_Diagnostics — Diagnóstico del dataset

Información sobre el tamaño del conjunto de entrenamiento, distribución de clases, número de descriptores seleccionados y razón de desbalance. Útil para verificar que el pipeline usó los datos esperados.

5.9 Hoja 10_PCA_Coordinates — Coordenadas PCA

Coordenadas en el espacio PCA (PC1, PC2, PC3) para todos los péptidos de entrenamiento y los nuevos. Permite visualizar dónde se ubican los nuevos péptidos en relación a las clases conocidas. Un péptido nuevo que cae dentro del “nube” de la clase objetivo en el espacio PCA refuerza la predicción positiva.

5.10 Hoja 1_Summary — Resumen

Tabla de resumen con los parámetros usados, las correcciones aplicadas en esta versión del script, el AUC de cada modelo y el conteo total de predicciones.

6. Gráficas PCA 3D interactivas

El script genera dos archivos HTML con gráficas tridimensionales interactivas del espacio de componentes principales. Abra estos archivos en cualquier navegador web.

6.1 AFP_PCA_3D_Training.html

Muestra únicamente los datos de entrenamiento. Los péptidos de la clase objetivo aparecen en un color y los demás en otro.

6.2 AFP_PCA_3D_Combined.html

Muestra los datos de entrenamiento, más los péptidos nuevos (en verde).

7. Errores comunes y cómo resolverlos

Error o síntoma	Causa probable	Solución
object 'train_data' not found	Los datos no se cargaron antes de ejecutar el script	Ejecutar primero los read_excel() para cargar train_data y new_data en el entorno de R
ERROR: Too few samples (X). Need at least 50.	El dataset de entrenamiento tiene menos de 50 filas después de limpiar duplicados	Aumentar el número de péptidos de entrenamiento o relajar el filtro de duplicados
ERROR: Only X features. Cannot proceed.	Quedaron menos de 5 descriptores después del filtro de AUC	Reducir auc_lower a 0.55 o 0.50, o revisar si los descriptores son adecuados para la clase objetivo
*** WARNING: leakage detected ***	Algunos péptidos del conjunto de prueba son idénticos a los de entrenamiento	Revisar los datos de entrada. Puede haber duplicados que el script no detectó porque difieren en algún descriptor por redondeo
Error in ranger(): mtry > n_cols	El número de descriptores es muy pequeño para la grilla de mtry configurada	Ocurre cuando quedan muy pocos descriptores. El script lo maneja automáticamente con make_rf_grid()
SMOTE: not enough unique minority samples	La clase minoritaria tiene muy pocas muestras para generar sintéticos	Agregar más péptidos de la clase minoritaria al dataset de entrenamiento, o poner comparison_class = NULL
All 3 models agree at 90%: 0	Ninguno de los nuevos péptidos es clasificado con muy alta confianza por todos los modelos	Puede ser un resultado válido. Revisar la hoja 3 con umbrales del 50% y 70%
PCA gráfica vacía o con error al abrir HTML	El archivo htmlwidgets no se guardó correctamente	Verificar que el paquete htmlwidgets está instalado y que hay permisos de escritura en el directorio de trabajo
Resultados muy diferentes entre ejecuciones	n_runs es demasiado bajo o el dataset es muy pequeño	Aumentar n_runs a 50 o más para estabilizar las predicciones