# Manual de Usuario

*Pipeline de Predicción de Actividad de Péptidos*

**Script:**
`peptide_activity_prediction_v7.R`

*Modelos: Random Forest + Red Neuronal (PCA) + Red Neuronal (ANOVA)*

*Versión 7 — 2025–2026 — Javier Badilla*

# 1. Introducción

Este script de R implementa un pipeline de aprendizaje automático para predecir si un péptido pertenece a una clase de actividad biológica determinada (por ejemplo: anticongelante AFP, antifúngíco FUNG, anticanceroso CANCER, inhibidor de AChE). A partir de descriptores moleculares numéricos calculados previamente, el pipeline entrena tres modelos independientes, los combina en un ensemble y genera predicciones calibradas con un nivel de confianza asignado.

El resultado final es un archivo Excel con 10 hojas que detallan las predicciones, el rendimiento de cada modelo, la importancia de los descriptores y la distribución espacial de los péptidos en el espacio de descriptores.

## 1.1 ¿Qué hace el script, en resumen?

| Etapa | Descripción |
|---|---|
| 1. Limpieza | Elimina duplicados, convierte etiquetas a binario (clase objetivo vs. todo lo demás), verifica desbalance de clases |
| 2. Selección de descriptores | Filtra descriptores por AUC individual ≥ 0.60, luego aplica filtro de correlación ≤ 0.90 para eliminar redundancias |
| 3. División train/test | Separa 80% para entrenamiento y 20% para evaluación. Esta división ocurre ANTES de la selección de descriptores para evitar fuga de datos |
| 4. Entrenamiento (20 corridas) | Entrena tres modelos independientes en cada corrida: Random Forest, Red Neuronal + PCA, Red Neuronal + ANOVA. Cada corrida usa una semilla diferente para medir estabilidad |
| 5. Calibración | Aplica escalado de Platt para corregir las probabilidades brutas de cada modelo |
| 6. Ensemble | Combina los tres modelos con pesos proporcionales al AUC promedio de cada uno |
| 7. Predicciones | Genera probabilidades y clasificaciones a tres umbrales (50%, 70%, 90%) con nivel de confianza |
| 8. Salida | Escribe un Excel con 10 hojas y dos gráficas PCA 3D interactivas en HTML |

## 1.2 Conceptos clave

**Descriptores moleculares:** Valores numéricos que describen propiedades físicoquímicas de un péptido (carga, hidrofobicidad, peso molecular, etc.). Son la entrada del modelo.

**AUC (Area Under the Curve):** Métrica de rendimiento de un clasificador. Va de 0.5 (aleatorio) a 1.0 (perfecto). Un descriptor con AUC alto puede por sí solo discriminar entre clases.

**Random Forest (RF):** Método de ensamble de árboles de decisión. Robusto ante descriptores irrelevantes y distribución no normal. Proporciona importancia de descriptores.

**Red Neuronal (NN):** Modelo de aprendizaje profundo simplificado (una capa oculta). Más flexible que RF pero requiere normalización de datos.

**PCA (Análisis de Componentes Principales):** Reduce dimensionalidad combinando descriptores correlacionados en componentes ortogonales. Se usa como preprocesado para una de las redes neuronales.

**Ensemble ponderado:** Combinación de los tres modelos donde cada uno contribuye en proporción a su AUC promedio. Reduce la varianza de predicción y mejora la robustez.

**Escalado de Platt:** Ajuste de las probabilidades brutas del modelo usando una regresión logística sobre un subconjunto de calibración. Corrige el sesgo sistemático de probabilidades en RF y NN.

**SMOTE:** Técnica de sobremuestreo sintético. Se aplica automáticamente cuando la clase mayoritaria supera en más de 3x a la minoritaria, para evitar que el modelo ignore la clase rara.

## 1.3 Requisitos del sistema

| Elemento | Versión mínima | Notas |
|---|---|---|
| R | 4.3+ | Requerido para compatibilidad con recipes y themis |
| readxl | cualquiera | Lectura de archivos Excel de entrada |
| openxlsx | cualquiera | Escritura del Excel de salida |
| caret | 6.0+ | Marco de entrenamiento y validación cruzada |
| ranger | 0.14+ | Implementación eficiente de Random Forest |
| nnet | cualquiera | Red neuronal de una capa oculta |
| pROC | cualquiera | Cálculo de AUC y curvas ROC |
| recipes | 1.0+ | Preprocesado declarativo de datos |
| themis | cualquiera | Implementación de SMOTE para desbalance |
| dplyr | 1.0+ | Manipulación de dataframes |
| plotly | cualquiera | Gráficas PCA 3D interactivas |
| htmlwidgets | cualquiera | Guardado de gráficas como HTML |

Para instalar todos los paquetes de una vez, ejecute en R:

```
install.packages(c("readxl","openxlsx","caret","ranger","nnet",
"pROC","dplyr","recipes","themis","plotly","htmlwidgets"))
```

# 2. Preparación de datos

## 2.1 Formato de los archivos de entrada

El script requiere dos objetos de datos ya cargados en el entorno de R antes de ejecutarse. Ambos deben estar en formato de dataframe (tabla).

### train_data — datos de entrenamiento

Tabla con péptidos de actividad conocida. Columnas obligatorias:

- **ID:** Identificador único de cada péptido (texto).
- **Type:** Clase de actividad (ej: AFP, FUNG, CANCER, AChE). Esta es la variable a predecir.
- **descriptor1, descriptor2, ...:** Valores numéricos de los descriptores moleculares.

```
# Ejemplo de estructura ID       | Type  | MW     | Charge | Hydrophobicity
| ... PEP_001  | AFP   | 1243.5 | +2     | 0.43           | ... PEP_002  |
FUNG  | 987.2  | -1     | 0.61           | ...
```

### new_data — péptidos nuevos a predecir

Tabla con los péptidos candidatos cuya actividad se desea predecir. Columnas obligatorias:

- **ID:** Identificador único.
- **descriptor1, descriptor2, ...:** Exactamente los mismos descriptores que en train_data, en el mismo orden. No lleva columna Type.

## 2.2 Procedimiento de carga recomendado

Cargue los datos en R antes de ejecutar el script principal:

```
library(readxl) train_data <- read_excel("train_data_capped_300.xlsx")
new_data   <- read_excel("mis_peptidos_nuevos.xlsx")
```

## 2.3 Preparación del conjunto de entrenamiento (cap a 300)

Si alguna clase tiene más de 300 muestras, se recomienda limitar a 300 antes de ejecutar el script. Esto evita que clases muy grandes dominen el entrenamiento y reduce el tiempo de cómputo. Use este código:

```
library(dplyr); library(openxlsx); set.seed(42) train_data_capped <-
train_data %>%   group_by(Type) %>%   slice_sample(n = 300, replace = FALSE)
%>%   ungroup() write.xlsx(train_data_capped, "train_data_capped_300.xlsx")
```

**Nota:** El parámetro replace = FALSE garantiza que no haya duplicados al samplear. La semilla set.seed(42) hace el muestreo reproducible.

# 3. Configuración del script

Antes de ejecutar el script, edite los parámetros en la sección USER INPUTS al inicio del archivo:

```
target_class     <- "AFP"    # clase que quiere predecir comparison_class <-
"FUNG"  # NULL = uno contra todos  n_runs            <- 20      # número de
corridas de entrenamiento prob_threshold   <- 0.90    # umbral para columnas
de frecuencia  auc_lower        <- 0.60    # AUC mínimo para conservar un
descriptor corr_threshold   <- 0.90    # umbral para filtro de correlación
```

| Parámetro | Tipo | Descripción | Valor recomendado |
|---|---|---|---|
| target_class | texto | La clase que el modelo aprenderá a identificar. Debe existir en la columna Type del train_data. | Ej: "AFP", "FUNG" |
| comparison_class | texto o NULL | Si se especifica, el modelo solo entrena con target_class vs. esta clase. Si es NULL, entrena target_class contra todas las demás clases combinadas. | NULL para análisis general; especificar cuando las clases son muy distintas entre sí |
| n_runs | entero | Cuántas veces se repite el ciclo completo de entrenamiento con semillas diferentes. Más corridas = predicciones más estables pero mayor tiempo. | 20 (mínimo recomendado); 50 para publicación |
| prob_threshold | decimal 0-1 | Umbral para calcular con qué frecuencia cada modelo supera ese nivel de probabilidad en las corridas. Se usa en las columnas RF_Freq, NN_PCA_Freq, NN_Desc_Freq. | 0.90 |
| auc_lower | decimal 0-1 | AUC mínimo que debe tener un descriptor individualmente para ser conservado. Descriptores por debajo se eliminan. | 0.60 (se relaja a 0.55 automáticamente si quedan menos de 10 descriptores) |
| corr_threshold | decimal 0-1 | Si dos descriptores tienen una correlación mayor a este valor, uno se elimina. Reduce redundancia. | 0.90 |

## 3.1 Modos de clasificación

### Modo uno contra todos (comparison_class = NULL)

El modelo aprende a distinguir la clase objetivo de TODAS las demás clases combinadas. Único cuando se tiene un conjunto diverso de péptidos no relacionados como clase negativa. Es el modo más general.

### Modo binario estricto (comparison_class = "FUNG")

El modelo solo entrena con los péptidos de las dos clases especificadas. El conjunto de entrenamiento se filtra previamente. Este modo es más preciso cuando las dos clases son las de mayor interés comparativo, pero puede sobreajustarse si las clases son muy similares.

# 4. Ejecución del script

## 4.1 Pasos para correr el script

1. Abra RStudio o la consola de R.
2. Cargue los datos de entrenamiento y los nuevos péptidos (ver sección 2.2).
3. Abra el archivo peptide_activity_prediction_v7.R.
4. Edite la sección USER INPUTS con su clase objetivo y parámetros (ver sección 3).
5. Ejecute el script completo (Ctrl+Shift+Enter en RStudio, o source("peptide_activity_prediction_v7.R") en consola).
6. El script imprime en consola el progreso de cada corrida. Con n_runs = 20, el tiempo típico es 10–40 minutos dependiendo del tamaño del dataset.

## 4.2 Qué aparece en consola durante la ejecución

El script imprime información de progreso en cada etapa. A continuación se describe lo que verá:

| Mensaje en consola | Qué significa |
|---|---|
| Class distribution: | Conteo de muestras por clase en el conjunto de entrenamiento |
| Imbalance ratio: X.XX | Razón entre la clase más frecuente y la menos frecuente. Si supera 3, se activará SMOTE |
| *** Imbalance > 3 detected - SMOTE will be applied *** | Aviso: el dataset está desbalanceado y se aplicará sobremuestreo sintético automáticamente |
| Features with AUC >= 0.60: XX | Número de descriptores que pasaron el primer filtro |
| Duplicate samples between train/test: 0 | Confirmación de que no hay fuga de datos entre entrenamiento y prueba |
| ===== RUN X of 20 ===== | Inicio de cada corrida del bucle de entrenamiento |
| [RF] Post-corr columns: XX \| Grid: YY combos | Número de descriptores después del filtro de correlación y tamaño de la grilla de búsqueda para RF |
| [RF] Test AUC: 0.XXXX | AUC del Random Forest en esa corrida sobre el conjunto de prueba externo |
| [NN-PCA] Test AUC: 0.XXXX | AUC de la Red Neuronal + PCA en esa corrida |
| [NN-ANOVA] Test AUC: 0.XXXX | AUC de la Red Neuronal + ANOVA en esa corrida |
| Model weights: RF: 0.XX NN_PCA: 0.XX NN_ANOVA: 0.XX | Pesos asignados a cada modelo en el ensemble, proporcionales a su AUC promedio |
| HIGH-CONFIDENCE AFP CANDIDATES: X | Número de péptidos nuevos con predicción positiva a umbral 70% y confianza Alta o Muy Alta |

## 4.3 Archivos generados

| Archivo | Descripción |
|---|---|
| AFP_Complete_Analysis_v2_clean.xlsx | Excel principal con 10 hojas de resultados (el prefijo cambia según target_class) |

| | |
|---|---|
| AFP_PCA_3D_Training.html | Gráfica 3D interactiva del espacio PCA solo con datos de entrenamiento |
| AFP_PCA_3D_Combined.html | Gráfica 3D interactiva con datos de entrenamiento Y péptidos nuevos superpuestos |

# 5. Interpretación del archivo Excel de salida

El Excel contiene 10 hojas. A continuación se describe el contenido y la interpretación de cada una, en orden de prioridad práctica.

## 5.1 Hoja 2_Simple_Predictions — Predicciones simplificadas

Es la hoja más directa y la primera que debe revisar. Tiene una fila por cada péptido nuevo.

| Columna | Qué significa |
|---|---|
| ID | Identificador del péptido, tomado de new_data |
| Is_AFP (o Is_[clase]) | YES si la probabilidad ensemble supera el 50%, NO en caso contrario |
| AFP_Probability_% | Probabilidad ensemble expresada en porcentaje (0–100). Representa la confianza combinada de los tres modelos de que el péptido pertenece a la clase objetivo |
| Confidence | Nivel de confianza cualitativo (Very High / High / Medium / Low). Ver tabla de rangos abajo |

| Confidence | Rango de probabilidad | Interpretación |
|---|---|---|
| Very High | > 90% o < 10% | Los tres modelos coinciden ampliamente. Predicción muy robusta. |
| High | > 70% o < 30% | Clara mayoría de los modelos coincide. Predicción confiable. |
| Medium | > 60% o < 40% | Tendencia clara pero no contundente. Considerar contexto. |
| Low | 40% – 60% | Zona de incertidumbre. Los modelos no tienen consenso. Interpretar con cautela. |

## 5.2 Hoja 4_High_Confidence — Candidatos de alta confianza

Lista filtrada con solo los péptidos que cumplen ambas condiciones simultáneamente: predicción positiva al umbral del 70% Y nivel de confianza High o Very High. Esta es la lista de candidatos prioritarios para validación experimental.

Están ordenados de mayor a menor probabilidad ensemble. Si un péptido aparece aquí con Confidence Very High y los tres modelos de acuerdo (Models_Agree_90 = 3), es el candidato más sólido del análisis.

## 5.3 Hoja 3_Detailed_Predictions — Predicciones detalladas

Contiene toda la información de predicción para cada péptido. Úl para análisis más granular.

| Columna | Qué significa |
|---|---|
| Ensemble_Probability | Probabilidad final ponderada por AUC de los tres modelos (valor entre 0 y 1) |

| | |
|---|---|
| Prediction_50 | Predicción usando umbral del 50%: clásico, maximiza el número de positivos detectados pero puede incluir falsos positivos |
| Prediction_70 | Umbral del 70%: balance entre precisión y recall. Recomendado para selección de candidatos |
| Prediction_90 | Umbral del 90%: solo los más seguros. Muy conservador, puede perder positivos reales |
| Confidence | Nivel de confianza cualitativo (igual que en hoja 2) |
| Models_Agree_90 | Cuántos de los 3 modelos superaron el umbral de 90% en el promedio de corridas. Valor de 0 a 3. 3 = consenso total |
| RF_Prob | Probabilidad promedio del Random Forest en las 20 corridas |
| NN_PCA_Prob | Probabilidad promedio de la Red Neuronal + PCA en las 20 corridas |
| NN_DESC_Prob | Probabilidad promedio de la Red Neuronal + ANOVA en las 20 corridas |
| RF_Pred / NN_PCA_Pred / NN_DESC_Pred | Predicción individual de cada modelo al umbral del 50% |
| Interpretation | Resumen en texto: 'POSITIVE for AFP (High confidence)' |

## 5.4 Hoja 5_Consensus — Análisis de consenso

Muestra con qué frecuencia, a lo largo de las 20 corridas, cada modelo clasificó al péptido como positivo al umbral configurado (prob_threshold = 0.90 por defecto).

| Columna | Qué significa |
|---|---|
| RF_Mean / NN_PCA_Mean / NN_Desc_Mean | Probabilidad promedio de cada modelo a lo largo de las 20 corridas |
| RF_SD / NN_PCA_SD / NN_Desc_SD | Desviación estándar entre corridas. Un SD alto indica que el modelo es inestable para ese péptido |
| RF_Freq / NN_PCA_Freq / NN_Desc_Freq | Fracción de las 20 corridas en que el modelo superó el umbral (0.90). Ej: 0.85 = superó el umbral en 17 de 20 corridas |
| Consensus_Mean | Promedio de las tres frecuencias. Mide qué tan consistentemente todos los modelos clasifican el péptido como positivo |
| Models_80 | Número de modelos que superaron frecuencia ≥ 0.80 |
| Confidence_Tier | Very High: Consensus_Mean ≥ 0.9 y los 3 modelos con frecuencia ≥ 0.8. High: Consensus_Mean ≥ 0.8 y al menos 2 modelos. Low: resto |

**Cómo interpretar el SD:** Un péptido con probabilidad promedio 0.85 pero SD = 0.20 indica que en algunas corridas el modelo lo clasificó como positivo fuerte y en otras como negativo. Esto señala que la predicción es sensible a la muestra de entrenamiento y debe tomarse con cautela. Un SD ≤ 0.10 indica robustez.

## 5.5 Hoja 6_Model_Evaluation — Rendimiento de los modelos

Resumen del rendimiento de cada modelo medido en el conjunto de prueba externo (el 20% reservado antes del entrenamiento).

| Columna | Qué significa |
|---|---|
| Model | Nombre del modelo: RF, NN_PCA, NN_DESC_ANOVA, Ensemble_Weight |
| Mean_AUC | AUC promedio en las 20 corridas. Es la métrica principal de calidad del modelo |
| SD_AUC | Variabilidad del AUC entre corridas. Un SD alto (≥ 0.05) indica inestabilidad |
| Min_AUC / Max_AUC | Valores extremos del AUC en las 20 corridas. Permiten ver el rango de rendimiento |
| Ensemble_Weight | Peso asignado al modelo en el ensemble. Proporcional a su Mean_AUC. Solo para los tres modelos base (no para Ensemble_Weight) |

| AUC promedio | Calidad del modelo |
|---|---|
| ≥ 0.90 | Excelente. El modelo discrimina muy bien entre clases. |
| 0.80 – 0.89 | Bueno. Predicciones confiables. |
| 0.70 – 0.79 | Aceptable. Útil pero con limitaciones. |
| 0.60 – 0.69 | Débil. Las predicciones deben tomarse como indicativas. |
| < 0.60 | Poco mejor que azar. Revisar calidad de los datos de entrenamiento. |

## 5.6 Hoja 7_Feature_Importance — Importancia de descriptores

Lista todos los descriptores usados por el Random Forest ordenados de mayor a menor importancia. La importancia se calcula por permutación: cuánto empeora el modelo al aleatorizar ese descriptor.

Los descriptores con mayor importancia son los más informativos para distinguir la clase objetivo. Esta información puede guiar el diseño de nuevos péptidos: un péptido nuevo con valores favorables en los descriptores de alta importancia tiene mayor probabilidad de ser clasificado como positivo.

El script también imprime en consola si la clasificación se basa en pocos descriptores (top 5 > 70% de la importancia total) o si está distribuida entre muchos.

## 5.7 Hoja 8_Top_Features_Stats — Estadísticas de los 5 mejores descriptores

Para los 5 descriptores más importantes, muestra el valor promedio en la clase objetivo (Target_Mean) y en la clase de comparación (Other_Mean), así como la diferencia entre ambos. Permite entender en qué dirección debe estar el descriptor para que un péptido sea clasificado como positivo.

**Ejemplo de interpretación:** Si Hydrophobicity tiene Target_Mean = 0.65 y Other_Mean = 0.32, significa que los péptidos AFP típicamente tienen mayor hidrofobicidad que los demás. Un nuevo péptido con hidrofobicidad alta tendrá más probabilidad de ser clasificado como AFP.

### 5.8 Hoja 9_Diagnostics — Diagnóstico del dataset

Información sobre el tamaño del conjunto de entrenamiento, distribución de clases, número de descriptores seleccionados y razón de desbalance. Úil para verificar que el pipeline usó los datos esperados.

### 5.9 Hoja 10_PCA_Coordinates — Coordenadas PCA

Coordenadas en el espacio PCA (PC1, PC2, PC3) para todos los péptidos de entrenamiento y los nuevos. Permite visualizar dónde se ubican los nuevos péptidos en relación a las clases conocidas. Un péptido nuevo que cae dentro del “nube” de la clase objetivo en el espacio PCA refuerza la predicción positiva.

### 5.10 Hoja 1_Summary — Resumen ejecutivo

Tabla de resumen con los parámetros usados, las correcciones aplicadas en esta versión del script, el AUC de cada modelo y el conteo total de predicciones. Es la primera hoja pero se recomienda leerla última, una vez se entiende el resto del análisis.

# 6. Gráficas PCA 3D interactivas

El script genera dos archivos HTML con gráficas tridimensionales interactivas del espacio de componentes principales. Abra estos archivos en cualquier navegador web.

## 6.1 AFP_PCA_3D_Training.html

Muestra únicamente los datos de entrenamiento. Los péptidos de la clase objetivo aparecen en un color y los demás en otro. Permite evaluar visualmente si las clases son separables en el espacio de descriptores. Si las nubes de puntos están claramente separadas, el modelo tendrá buen rendimiento.

## 6.2 AFP_PCA_3D_Combined.html

Muestra los datos de entrenamiento (dos colores por clase) más los péptidos nuevos (en verde, forma de diamante). Esta es la gráfica más informativa: permite ver si los péptidos nuevos se ubican dentro de la nube de la clase objetivo o en otra región del espacio.

**Cómo interpretar la posición de un péptido nuevo:**

- Si cae dentro o cerca de la nube de la clase objetivo: la predicción positiva está respaldada por la estructura de los datos.
- Si cae en una zona intermedia: la predicción es incierta incluso si la probabilidad numérica parece alta.
- Si cae claramente en la nube de otra clase: desconfiar de una predicción positiva del ensemble.

**Nota sobre la varianza explicada:** Los tres componentes principales no capturan el 100% de la variación de los descriptores. El porcentaje explicado se indica en los ejes de la gráfica. Si PC1+PC2+PC3 explican menos del 50% de la varianza, la gráfica es solo una proyección parcial y debe interpretarse con precaución.

# 7. Criterio de decisión: ¿qué péptidos avanzan?

La decisión de qué péptidos pasan a síntesis y validación experimental debe basarse en múltiples indicadores del Excel, no solo en la probabilidad ensemble. Se recomienda el siguiente proceso:

## 7.1 Criterios de avance recomendados

| Criterio | Umbral mínimo | Umbral ideal |
|---|---|---|
| Ensemble_Probability (hoja 2) | > 0.70 | > 0.85 |
| Confidence (hoja 2) | High | Very High |
| Models_Agree_90 (hoja 3) | ≥ 2 de 3 | 3 de 3 |
| RF_Freq + NN_PCA_Freq + NN_Desc_Freq (hoja 5) | Al menos 2 con frecuencia ≥ 0.70 | Los 3 con frecuencia ≥ 0.80 |
| SD de probabilidad (hoja 5) | < 0.20 | < 0.10 |
| AUC del modelo (hoja 6) | Mean_AUC ≥ 0.75 | Mean_AUC ≥ 0.85 |
| PCA (gráfica Combined) | Péptido cercano a la nube de la clase objetivo | Péptido dentro de la nube |

## 7.2 Casos de descarte automático

Un péptido debe descartarse aunque tenga probabilidad alta si:

- El AUC promedio del mejor modelo es < 0.65. En ese caso el modelo en sí no es confiable y las predicciones no son válidas.
- El SD de probabilidad del péptido supera 0.25. Indica que la predicción es altamente dependiente de la muestra de entrenamiento.
- Solo uno de los tres modelos lo clasifica como positivo (Models_Agree_90 = 0 o 1 y los otros dos negativos con alta confianza).
- La gráfica PCA muestra que el péptido cae claramente en la nube de otra clase, contradiciedo la predicción numérica.

## 7.3 Interpretación cuando hay pocos candidatos

Si la hoja 4_High_Confidence queda vacía o con muy pocos péptidos, hay varias posibilidades:

- Los nuevos péptidos genuinamente no son similares a la clase objetivo en el espacio de descriptores.
- El modelo es demasiado conservador. Revise la hoja 3 con umbral del 50% para ver si hay positivos marginales que podrían valer la pena explorar.
- La clase objetivo en el entrenamiento tiene muy pocas muestras o los descriptores no son informativos. Revise la hoja 6: si el AUC promedio es < 0.70, el modelo tiene poca capacidad discriminatoria.

## 8. Errores comunes y cómo resolverlos

| Error o síntoma | Causa probable | Solución |
|---|---|---|
| object 'train_data' not found | Los datos no se cargaron antes de ejecutar el script | Ejecutar primero los read_excel() para cargar train_data y new_data en el entorno de R |
| ERROR: Too few samples (X). Need at least 50. | El dataset de entrenamiento tiene menos de 50 filas después de limpiar duplicados | Aumentar el número de péptidos de entrenamiento o relajar el filtro de duplicados |
| ERROR: Only X features. Cannot proceed. | Quedaron menos de 5 descriptores después del filtro de AUC | Reducir auc_lower a 0.55 o 0.50, o revisar si los descriptores son adecuados para la clase objetivo |
| *** WARNING: leakage detected *** | Algunos péptidos del conjunto de prueba son idénticos a los de entrenamiento | Revisar los datos de entrada. Puede haber duplicados que el script no detectó porque difieren en algún descriptor por redondeo |
| Error in ranger(): mtry > n_cols | El número de descriptores es muy pequeño para la grilla de mtry configurada | Ocurre cuando quedan muy pocos descriptores. El script lo maneja automáticamente con make_rf_grid() |
| SMOTE: not enough unique minority samples | La clase minoritaria tiene muy pocas muestras para generar sintéticos | Agregar más péptidos de la clase minoritaria al dataset de entrenamiento, o poner comparison_class = NULL |
| All 3 models agree at 90%: 0 | Ninguno de los nuevos péptidos es clasificado con muy alta confianza por todos los modelos | Puede ser un resultado válido. Revisar la hoja 3 con umbrales del 50% y 70% |
| PCA gráfica vacía o con error al abrir HTML | El archivo htmlwidgets no se guardó correctamente | Verificar que el paquete htmlwidgets está instalado y que hay permisos de escritura en el directorio de trabajo |
| Resultados muy diferentes entre ejecuciones | n_runs es demasiado bajo o el dataset es muy pequeño | Aumentar n_runs a 50 o más para estabilizar las predicciones |

## 9. Guía rápida de uso

Para un usuario que ya conoce el script, estos son los pasos completos de principio a fin:

7. **Preparar datos:** Calcule los descriptores moleculares de sus péptidos de entrenamiento (con actividad conocida) y de los nuevos candidatos.
8. **Cargar en R:** read_excel() para train_data (con columnas ID, Type, descriptores) y new_data (con columnas ID, descriptores).
9. **Cap a 300:** Si alguna clase tiene más de 300 muestras, aplicar el snippet de slice_sample del encabezado del script.
10. **Configurar:** Editar target_class, comparison_class, n_runs en la sección USER INPUTS.
11. **Ejecutar:** Correr el script completo. Esperar entre 10 y 60 minutos según el tamaño del dataset y n_runs.
12. **Revisar consola:** Verificar que el AUC de los modelos sea ≥ 0.75 y que no haya advertencias de leakage o SMOTE inesperado.
13. **Abrir Excel:** Ir directamente a la hoja 4_High_Confidence para ver los candidatos prioritarios. Cruzar con la hoja 5_Consensus para verificar estabilidad.
14. **Revisar PCA:** Abrir AFP_PCA_3D_Combined.html y verificar que los candidatos positivos se ubican cerca de la nube de la clase objetivo.
15. **Decidir:** Usar la tabla de criterios de la sección 7.1 para seleccionar qué péptidos pasan a síntesis.

*Script: peptide_activity_prediction_v7.R — Autor: Javier Badilla — Modelos: Random Forest + Red Neuronal (PCA) + Red Neuronal (ANOVA) — Ensemble ponderado por AUC — Calibración: Platt scaling*